

Описание проекта по развитию кредитного скоринга в розничном бизнесе¹

Задача

Разработать модель кредитного скоринга для департамента рисков розничного бизнеса (беззалоговое кредитование). Модель предсказывает вероятность серьёзной просрочки по заявке в горизонте 2 лет. Решение позволит автоматизировать часть ручных проверок (сейчас 45% заявок обрабатываются вручную) и повысить качество ранжирования риска. Базовая модель (логистическая регрессия) имеет ROC-AUC = 0.70; предлагаемый ML-подход (LightGBM) даёт ROC-AUC $\approx$ 0.87, что улучшает отбор заявок и снижает операционную нагрузку.

Данные

Используется публичный датасет Give Me Some Credit с Kaggle, содержащий табличные признаки заёмщиков: кредитная утилизация, возраст, история просрочек, долговая нагрузка, доход, число кредитных линий, число иждивенцев. Пропуски обработаны импутацией с добавлением индикаторов.

В пайплайн включён feature engineering:

- total_past_due_events – общее количество просрочек за историю
- weighted_past_due_score – взвешенный балл просрочек (с учётом тяжести)
- income_per_dependent – доход на одного иждивенца
- debt_per_income – отношение долга к доходу
- real_estate_share – доля недвижимости в активах
- past_due_per_open_line – средняя просрочка на открытую кредитную линию

Модель и пайплайн

Пайплайн включает загрузку данных, предобработку, генерацию признаков, обучение LightGBM с подбором гиперпараметров через Optuna. Модель интерпретируется через SHAP и feature importance. Решение воспроизводимо, зависимости зафиксированы.

Метрики

Бизнес-метрика – снижение доли ручной проверки при сохранении качества риска. Основная ML-метрика – ROC-AUC (0.70 $\rightarrow$ 0.87) для ранжирования клиентов. Дополнительно: PR-AUC, KS, precision/recall на порогах. Операционный эффект – сокращение ручного просмотра на 10–15 п.п., ускорение обработки заявок.

Анализ ошибок и риски

Проанализированы false positive (модель завышает риск) и false negative (пропуск дефолта). Причины – агрессивные паттерны просрочек или недостаток внешних данных. Основные риски: data/concept drift, атаки на модель, регуляторные требования к объяснимости, стоимость ошибки false negative.

План мониторинга

В production отслеживаются: распределение скоры, доля одобрений/отказов, PSI по ключевым признакам и скору, ROC-AUC/PR-AUC на размеченных данных, доля ручной проверки. Пороги: при $PSI \geq 0.25$ – расследование; при падении ROC-AUC > 0.05 – перевод части потока на ручную проверку; при серьёзной деградации – откат на логистическую регрессию с бизнес-правилами. Мониторинг ежечасный (распределение, PSI) и ежемесячный (качество на накопленных таргетах). Ответственные – владелец модели и DS-команда.

Состав команды и вклад

Конушкин Егор – бизнес-анализ, постановка задачи, описание текущего процесса, ожидаемый эффект, вводная часть презентации.

Щербаков Игорь – техническая реализация: подготовка данных, preprocessing, feature engineering, обучение LightGBM, подбор гиперпараметров, воспроизводимый пайплайн.

Бакало Никита – оценка качества, интерпретация (SHAP, графики), разбор ошибок, описание production-рисков, мониторинг и план отката, финальная упаковка материалов.

¹ Ссылка на репозиторий: https://github.com/Falconwatch/fintech_ai_light